

CERTIFICATION AIA — BLOC 4

MLOps : industrialiser le cycle de vie du modèle

Prédiction d'attrition RH — déploiement, monitoring et réentraînement


Ahmed Mehdi SEMAR

Certification AIA — Architecte en Intelligence Artificielle · Soutenance : 5 min + 10 min de questions




Contexte et objectif

- Cas métier : prédire le risque de départ d'un employé (attrition).
- Objectif : couvrir tout le cycle de vie, pas seulement l'entraînement.
- Deux dépôts : bloc4_mlops (ETL, API, MLflow) et train-repo (entraînement + monitoring).
- Modèle servi via API REST ; données scorées en continu par l'ETL.



Architecture MLOps


Bloc 4 — Architecture MLOps (service + ETL)



Service (API, MLflow) et pipeline ETL ; le train-repo alimente le registre et lit la prod.

Boucle monitoring → réentraînement

train-repo — Boucle monitoring / réentraînement



Dérive détectée → réentraînement automatique d'un challenger ; promotion en production manuelle.

Entraînement et versioning

1 Entraînement rigoureux

split stratifié, class_weight balanced, GridSearchCV optimisé sur le F1.

2 Évaluation honnête

métriques de test : precision, recall, F1, ROC-AUC, matrice de confusion.

3 Versioning des modèles

MLflow Registry ; alias challenger / production matérialisant les états de service.

4 Rollback

repointer l'alias production sur une version antérieure, sans toucher au code.

CI/CD et déploiement

1

Intégration continue ci.yaml : tests pytest + build Docker + exécution bornée de l'ETL.

2

Réentraînement train.yaml : déclenchement manuel, sur push ou sur pull request.

3

Déploiement API FastAPI conteneurisée sur Hugging Face, servant le modèle @production.

4

Simulation de prod ETL avec ordonnanceur borné (ETL_LOOP_ITERATIONS) : prod en continu, CI auto-terminante.


Bilan et perspectives

- Attendus couverts : entraînement, déploiement, CI/CD, monitoring, réentraînement, versioning/rollback, documentation API.
- Évolution assumée : gate automatique champion/challenger avant promotion.
- Évolutions : alerting actif sur dérive et passage à l'échelle (ECS / Kubernetes).

Merci — questions ?

Annexe — Pipeline ETL (etl.py)

Bloc 4 — Pipeline ETL (etl.py)



Extract → Transform (scoring) → Load, encapsulé dans un ordonnanceur borné.

Annexe — Périmètre du monitoring

- Référence = jeu d'entraînement ; production = agrégat fenêtré des prédictions sur S3.
- Mesuré : dérive des entrées (covariate shift) et dérive des prédictions.
- Non mesuré : accuracy en ligne — nécessiterait la collecte a posteriori des départs réels.
- Seuil de dérive paramétrable ; rapport HTML archivé en artefact et sur S3.